

学士学位论文

基于 LightGBM 和 Catboost 双模型 堆叠策略下的贷款违约风险预测分析

学 号:	20211002564
姓 名:	何子欣
学 科 专 业:	会计学
指 导 教 师:	杨海霞 讲师
培 养 单 位:	经济管理学院

二〇二五年五月

中国地质大学（武汉）学士学位论文原创性声明

本人郑重声明：本人所呈交的学士学位论文《基于 LightGBM 和 Catboost 双模型堆叠策略下的贷款违约风险预测分析》，是本人在指导老师的指导下，在中国地质大学（武汉）攻读学士学位期间独立进行研究工作所取得的成果。论文中除已注明部分外不包含他人已发表或已撰写过的研究成果，对论文的完成提供过帮助的有关人员已在文中说明并致以谢意。

本人所呈交的学士学位论文没有违反学术道德和学术规范，没有侵权行为，并愿意承担由此而产生的法律责任和法律后果。

学位论文作者签名 何子欣
日 期： 2025 年 6 月 6 日

摘要

随着海外消费信贷市场的持续扩张，信贷欺诈行为日益复杂化、隐蔽化，传统风控手段难以有效应对。本研究基于 HomeCredit 公开数据，采用机器学习技术构建智能化贷款违约预测模型，旨在为金融机构提供高效、精准的风控解决方案。

首先，本研究系统梳理了消费金融行业的发展现状，并分析了机器学习技术在风控领域的应用现状及理论基础。结合业务需求，从工业角度设计了模型架构与优化策略。在数据预处理阶段，通过空缺值填补、格式转换及特征衍生（涵盖消费水平与行为变化两个维度），共计构建 472 个特征变量。针对类别不平衡问题，采用分层五折交叉验证方法，创新性地结合 LightGBM 与 CatBoost 双模型进行集成训练，并引入软投票与时间动态调整机制，显著提升了模型的鲁棒性。

实验结果表明，客户还款能力、支付历史行为和逾期记录是预测违约风险的三大关键特征。此外，本研究通过评分校准将违约概率转化为信用评分，为金融机构建立透明化的信用评价体系提供了科学参考。本研究不仅验证了机器学习技术在风控领域的实用价值，还为金融机构优化风控策略提供了新的思路。未来研究可进一步探索时间序列动态优化方法，以提升模型的实时性与预测精度。

关键词：风控；LightGBM 模型；Catboost 模型；分层五折交叉验证

Abstract

With the overseas consumer credit market gradually expanding, fraudulent activities become increasingly sophisticated and elusive, which challenge traditional risk control methods. This study develops an intelligent default prediction model using HomeCredit's data, aiming to provide consumer financial institutions with efficient and accurate risk management solutions.

The research begins with a systematic review of the consumer finance industry's development. Then the article analyzed both the theories of machine learning and its applications in credit risk. Following the above, detailed requirements and the architecture design of models are indicated.

When model construction, we conducted comprehensive data interpretation and its related exploratory analysis. Through data preprocessing and feature engineering (eg: consumption levels and behavioral patterns), there are 472 characteristic variables for training in total. To address class imbalance and meet the industry requirements, LightGBM and CatBoost are used for prediction in an ensemble strategy with a stratified five-fold cross-validation approach employed. What's more, in order to improve the robustness of the model, both soft voting mechanisms and time-based dynamic adjustments are introduced in the model.

Feature importance analysis from this research identifies three key factors to predict the default risks: repayment capacity, payment history, and delinquency records. Lastly, the study further transforms default probabilities from the model we built into credit scores through score calibration, establishing a transparent credit risk scoring system. Our findings not only validate the practical value of machine learning in risk management modeling but also provide a useful example for financial institutions to optimize their risk control strategies. In future, there are some improvements for this model. For example, dynamic scoring mechanisms regarding time series are worth for further research, which may be helpful to improve the accuracy.

Key words: Risk Control; LightGBM; Catboost; Stratified 5-Fold Cross-Validation

目 录

第一章 绪论	1
1.1 研究背景和意义	1
1.1.1 研究背景	1
1.1.2 研究意义	1
1.2 行业发展现状	1
1.3 研究现状及分析方法	3
1.1.3 研究现状	3
1.1.4 实现方法	4
1.4 论文结构	4
第二章 理论分析	6
2.1 信用评分卡	6
2.1.1 信用评分卡的目的与意义	6
2.1.2 信贷评分卡在风控策略的具体应用	6
2.1.3 未来发展趋势	7
2.2 机器学习算法	8
2.2.1 特征工程-IV 值筛选	8
2.2.2 Logistics Regression	8
2.2.3 树模型架构	9
2.2.4 XGBoost 模型原理	9
2.2.5 LightGBM 核心原理	10
2.2.6 Catboost 核心原理	11
2.2.7 算法对比	11
第三章 需求分析与架构设计	13
3.1 论文核心问题阐述	13
3.2 模型需求分析	13
3.3 模型总体架构	14
第四章 基于数据集的违约预测模型构建	15
4.1 违约预测对象介绍	15
4.2 建模环境介绍	16
4.3 数据集解读与数据预处理	16
4.3.1 数据格式处理	16
4.3.2 缺失值与异常值处理	17

4.4 特征工程——特征衍生与数据聚合	17
4.4.1 消费水平	17
4.4.2 消费行为变化	19
4.5 模型训练与评估	20
4.6 特征重要性分析	22
4.7 模型优化	23
4.7.1 投票机制与线性融合	23
4.7.2 基于时间信息的预测结果微调	24
第五章 可视化应用与用户管理	25
5.1 分数校准	25
5.1.1 评分公式原理	25
5.1.2 评分链接实例	26
第六章 总结与展望	27
6.1 总结	27
6.1.1 工作总结	27
6.1.2 局限性	27
6.1.3 展望	28
致谢	29
参考文献	30
附录	33

图目录

图 1.1	消费金融公司总资产及贷款余额变化情况	2
图 1.2	消费金融市场主体对比	2
图 1.3	本文主要实现方法流程图	4
图 3.1	论文模型架构层次图	14
图 4.1	HomeCredit 公司 LOGO	15
图 4.2	Utility 类示图	16
图 4.3	Aggregator 类定义示图	19
图 4.4	日期特征处理示图	20
图 4.5	处理好的数据集	20
图 4.6	AUC 分数对比	21
图 4.7	Top20 特征重要性 (LightGBM)	22
图 4.8	模型预测结果文件读取	23
图 4.9	模型性能对比 (集成前后)	24
图 4.10	实验代码及结果显著	24
图 5.1	概率与评分链接的代码示图	26
图 5.2	评分输出 (部分)	26

表目录

表 2.1	信用评分卡具体分类	7
表 2.2	机器学习算法性能对比	12
表 4.1	预处理函数整理	17
表 4.2	消费变量整理	18
表 4.3	聚合类函数整理	19
表 4.4	特征分类解释	22

第一章 绪论

1.1 研究背景和意义

1.1.1 研究背景

随着中国消费金融公司出海布局的步伐加快，海外信贷业务规模呈现爆发式增长。艾瑞咨询数据显示，2021 年中国头部消费金融公司的海外信贷规模已突破 100 亿美元，其中蚂蚁集团 2024 年海外消费金融业务规模更达到 90 亿美元，稳居行业首位。预计到 2025 年，这一市场规模将超过 300 亿美元，东南亚和南亚地区将成为主要增长引擎。^[1]

然而，数字化发展的深入推进也为信贷风控带来了新的挑战。欺诈手段持续升级迭代，呈现出隐蔽化、智能化的新特征，传统的专家规则和会计审查等风控手段已难以有效应对。在此背景下，人工智能与机器学习技术的创新发展为金融机构构建智能风控体系提供了全新思路与应用解决方案。

1.1.2 研究意义

随着全球化进程的加速和金融科技的快速发展，海外消费信贷市场迅速扩张，基于 LightGBM 与 Catboost 双模型堆叠策略下的违规概率预测模型，不仅能够有效识别跨境信贷中的违约行为，还能提升金融机构的风控能力。本研究以 HomeCredit 为例，通过对其海量信贷数据进行建模分析，旨在探索大数据技术在反欺诈领域的应用潜力，构建违约预测模型，为全球消费信贷市场的健康发展提供理论支持和实践参考。

1.2 行业发展现状

截至 2023 年末，消费金融公司总资产及贷款余额双双突破一万亿元，增速较 2022 年明显提升，且远高于全国消费贷款余额增速。具体来看，2023 年末消费金融公司总资产较上年末增加 3,250 亿元，增量贡献前五的消费金融公司占比达 70%，其中蚂蚁消金承接花呗、借呗资源，总资产同比增长逾 1,300 亿元，居行业首位；部分城商行系消费金融公司在获得母行增资后发力个人消费贷款业务，实现业务规模的快速扩张。此外，截至 2023 年末，消费贷渗透率同比上升 1.84 个百分点至

40.11%，消费贷款余额同比增长 14.77%至 19.78 万亿元，其中消费金融公司业务余额占比 5.83%，份额占比虽较低但呈增长态势。^[15]




图 1.1 消费金融公司总资产及贷款余额变化情况

展望未来，在政策的持续刺激下消费信贷需求有望进一步修复，未来消费金融行业资产及信贷规模预计仍将持续扩大，长期来看利于整体消费金融行业的长远发展，但考虑到目前有效需求较为疲软、收入预期不佳以及消费降级的现状短期内尚难改变，短期内行业整体增速或更趋向平稳。

目前，消费金融市场参与主体呈多元化发展态势，形成了以传统商业银行为主、互联网金融平台、民营银行、消费金融公司及小贷公司为辅的消费金融市场格局。

	商业银行	民营银行	消费金融公司	互联网金融平台	小额贷款公司
业务规模	最高	较低	较低	较高	低
客群定位	中高收入群体	中低收入群体	全部群体	全部群体	中低收入群体
融资能力	最强	中等偏上	中等	中等偏上	中等
流量优势	流量中等	流量较差	流量中等	流量最好	流量较差
股东优势	明显	一般	较好	一般	较差
金融科技优势	强	中等	较强	最强	中等
资料来源：公开信息，联合资信整理					

图 1.2 消费金融市场主体对比

从竞争格局来看，商业银行是消费金融公司的主要发起机构，消费信贷中传统银行、信用卡占有主导地位，其次为银行的自营消费贷款，银行在资金成本及股东背景方面具备比较明显的优势；互联网金融平台是互联网消费金融最主要的

参与者，包括 360 数科、京东、蚂蚁、乐信等，互联网金融平台拥有场景、流量和技术优势，但由于近年来受到的监管政策限制较多，市场占有率增长一定程度受限；消费金融公司目前家数不多、整体资产规模不大。

2024 年上半年，在宏观环境具有不确定性、借款人还款能力有所弱化以及监管趋严的大背景之下，绝大部分头部消费金融公司资产规模在收缩；行业中部的消费金融公司实现了较好的增长，整体看，消费金融行业进入存量竞争的时代，不再单纯追求规模增长，行业内不同分层的消费金融公司经营情况或更趋向均衡。

1.3 研究现状及分析方法

1.1.3 研究现状

风控策略在信贷发展中有着举足轻重的地位。传统风控主要依赖人工经验、规则引擎和统计分析等方式对放贷涉及贷前、贷中、贷后全流程风险进行把控。其核心是通过预设规则、信用评分卡、财务分析等方式评估借款人风险。传统风控模式优势在于透明合规，但难以处理复杂特征交互，尤其是在海量数据面前难以在违约样本中察觉出一些非线性显著特征。随着时间发展，现代量化风控基于大数据、机器学习、实时计算等技术，通过数据驱动建模、自动化决策、动态监控实现精准风险管理。主要核心是量化分析、机器学习、实时响应并做到智能迭代。

目前量化风控在技术层面上，WOE-IV 特征工程与逻辑回归模型二者相混合的方式既提升预测准确性，同时还保证了特征可解释性。而在部分规则合规性要求相对没那么严格的消费金融机构中，LightGBM、XGBoost 等机器学习模型以及诸如 GNN、BERT 的深度学习模型也在随着业务需求的精细化刁钻化深入应用至反欺诈、违约预测等领域。业界反欺诈识别中，蚂蚁金服 18 年首次引入异构图神经网络（GEM）以检测恶意账户识别复杂关系网络中的欺诈团伙。^[24]技术阐述大致如下：首先构建账户-设备异构图，节点包括账户和多种设备，边表示登录关系，结合账户行为特征（如 168 维时间序列）和设备类型特征；采用多层图卷积动态聚合“设备聚集”和“活动聚集”模式，引入注意力机制自适应学习不同设备类型的重要性；最后通过节点嵌入和逻辑回归分类器实现端到端检测。验证实验中支付宝部署上线，每日筛选 Top 1 万的高风险账户，精度超 98%且覆盖率较规则方法提升 10%。该研究解决了传统机器学习方法（如连通子图、GBDT）在噪声数据下召回率低的问题。19 年谷歌 Transformer 结构与自注意力编码机制的提出，^[29]

京东数科通过自主搭建大模型，实现动态信用评分机制。尽管技术高速发展且数字风控已经得到了较好的完善，但是风控在技术领域上仍遇到一定的困难与挑战。例如，在机器学习建模中尽管有较为完善的模型训练框架，但常常也会遇到过拟合缺少泛化性的问题。如何让模型减少过拟合程度，提高预测泛化度，更甚者达到自适应调整将是未来的一个重要研究方向。同时因果推断科学与双重机器学习的出现与发展为特征相对于预测变量的相关性与因果性上带来了更科学的解释方法论。而目前的研究也仅仅止步于如何简单根据业务逻辑制定规则策略。因此如何通过创新数据手段控制过拟合情况进而达到有效预测风控，需得到进一步研究。本论文也将着手于此进行深入探讨。

1.1.4 实现方法




图 1.3 本文主要实现方法流程图

针对上述研究内容，本节主要描述相应的实现方法，具体如下：

- (1) 在数据探索方面，由于数据较多，主要查看了空缺值情况以及各特征数据类型；
- (2) 在数据预处理方面，直接删除空缺比较高的特征进行处理；此外对数据类型进行了统一等操作；
- (3) 在特征工程方面，从消费行为与用户动态变化两角度进行了特征衍生；
- (4) 在训练与可视化方面，采用 LightGBM 和 Catboost，以投票机制对二者进行融合得出最终概率。将概率链接评分公式，建立用户信用评分系统。

1.4 论文结构

首先绪论部分介绍了研究的背景、意义以及当前该领域的研究现状，同时在研究思路和方法板块详细介绍了本论文具体的实现方法。

在第二章节则是本论文的理论基础分享，通过该板块能够直观的容易的了解风控评分卡的具体应用场景，同时介绍本论文的机器学习算法基础与性能对比，为后文的详细模型建设奠定基础。

在第三章节则是对整个论文的核心解决问题介绍，通过该板块能够直观容易的了解本论文建模的核心解决问题以及具体需求分析；

在第四章节则为本论文的模型建立部分，在该部分详细介绍了输入变量、输出变量分别是什么、以代码为基础的特征工程与预处理操作思路。同时对具体的模型训练与优化进行了讲解，通过特征重要性分析挖掘了一些可以帮助制定信贷风控策略的规则与相关阈值设定。

第五章部分是可视化部分，主要是为了面向业务方与用户建立透明信用体系。通过最终输出概率与评分公式链接，生成个人对应评分，并方便客户分层管理。

最后，在结论与展望部分，总结研究的主要内容和结论，阐述了研究存在的缺陷，并展望在未来的发展。

第二章 理论分析

2.1 信用评分卡

信用评分卡是一种用于评估个人或企业信用风险的量化模型，广泛应用于银行、消费金融、保险等领域。它通过将客户的信用历史、财务状况、行为特征等转化为分数，帮助机构快速决策是否授信、定价或调整额度。

2.1.1 信用评分卡的目的与意义

信用评分卡的建立的主要目的是为了摆脱以往定性放贷乱象，减少人情贷等现象的出现。最早初的信用评分卡主要是通过问卷量表的形式进行打分进而预判风险。量化评分的使用不仅仅有助于评估用户违约概率，更有助于定量化分层客户，如根据分数将客户分为高中低风险三层面并分策略分层级进行客户的运营与召回。这种方式比起未出现评分卡前找人进行专业调查的方式更为节省人力，有助于提高决策效率，标准化流程，尤其适用于提高合规性。此外，这种从分数层面上分层运营，有助于精细化寻找欺诈样本，进而辨别新型欺诈特征，归纳最简欺诈规则进行捕捉。

此外，金融机构通过精准的风险评估模型，能够有效降低坏账率并减少不良贷款，同时优化利率和额度策略以提升盈利能力，并通过快速响应市场需求来增强竞争力和客户体验。对于客户而言，这种数据驱动的评估方式确保了授信公平性，减少了人为偏见，使信用良好的客户更容易获得贷款；同时，透明的信用评估体系（如征信报告、信用分）可以让客户清晰了解自身信用状况。优质客户还能享受更低利率和更高额度等个性化服务，从而实现金融机构与客户的双赢。

2.1.2 信贷评分卡在风控策略的具体应用

信贷策略主要涉及贷前、贷中、贷后以及反欺诈四个主要环节。四个环节中评分卡模型主要可以分成以下四大类：

表 2.1 信用评分卡具体分类

类型	用途
申请评分卡	评估新客户的信用风险（如贷款审批、信用卡申请）
行为评分卡	监控现有客户的还款行为（如调整额度、催收策略）
催收评分卡	预测逾期客户还款概率，优化催收资源分配
反欺诈评分卡	识别欺诈风险（如虚假申请、盗刷）

从表 2.1 中，可以了解四类评分卡主要适用于银行贷款、信用卡审批、消费金融、保险行业、互联网金融、租赁行业等业务场景。本文涉及的违约预测主要用于申请评分卡，通过搭建用户的未来违约概率预测模型，链接评分公式生成申请评分，进而完善成为系统中评分卡的一部分。由此看，预测模型的精确性以及评分公式的风格将很大程度上构筑着各银行与消费金融公司的独有竞争力。

2.1.3 未来发展趋势

· 实时风控与 AI 智能化

随着数据科学手段的深入发展，风控系统的业务要求逐渐精细化严格化，如何实现快速结合大数据（如社交痕迹、电商数据）动态调整信用分将成为风控未来发展的重点方向。而高性能 AI 大模型的陆续涌现（如 Deepseek、ChatGPT 等）也为实时风控的建设提供了一定的技术思路。未来如何将 AI 与实时风控相结合进而实现高要求度的业务需求还待观察。

· 联邦学习：跨机构数据协作，提升模型精度而不泄露隐私

联邦学习作为一种创新的分布式机器学习范式，正在重塑实时风控的协作模式。其核心在于“数据不动，模型动”——各参与机构无需共享原始数据，仅通过加密的模型参数交互，即可联合训练高精度风控模型。^[30]例如，多家银行可基于联邦学习共同构建反欺诈模型，既能识别跨机构的“多头借贷”等复杂风险，又严格保障用户隐私（符合 GDPR/《数据安全法》要求）。关键技术如差分隐私（添加噪声防止逆向推理）、安全聚合及异构数据对齐，在金融、医疗等领域已实现商业化落地。该技术既能打破“数据孤岛”又能同时满足信息合规，未来将成为行业中重要的技术解决方案之一。

2.2 机器学习算法

2.2.1 特征工程-IV 值筛选

IV (Information Value, 信息价值) 用于评估变量 (特征) 对目标变量 (如违约、逾期等) 的预测能力, 常常用于进行变量筛选, 衡量一个变量对二元目标变量 (如好坏客户) 的区分能力。

$$IV = \sum_{i=1}^n (\%Good_i - \%Bad_i) \times WOE_i \quad (2.1)$$

其中:

$\%Good_i$ 为第 i 个分箱中好客户占比 (如非违约客户) ;

$\%Bad_i$ 为第 i 个分箱中坏客户占比 (如违约客户) 。

WOE_i 为第 i 个分箱的证据权重, 计算公式:

$$WOE_i = \ln \left(\frac{\%Good_i}{\%Bad_i} \right) \quad (2.2)$$

2.2.2 Logistics Regression

在消费金融业务中, Logistics (也称 LR 回归) 在对变量的可解释性和二分类预测中上有着较好的优势, 因而在风控领域尤其是传统银行业得到广泛应用。

LR 回归使用 Sigmoid 函数 (即 Logistic 函数) 将线性组合 $z = \mathbf{w}^T \mathbf{x} + b$ 转换为概率:

公式具体如下:

$$P(y = 1|x) = h_{\mathbf{w}}(x) = \sigma(z) = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (2.3)$$

其中:

$\mathbf{w}$ 为权重向量;

$\mathbf{x}$ 为输入特征;

b 为偏置项;

$\sigma(z)$ 为 Sigmoid 函数, 输出范围 (0, 1) 。

而二分类回归预测常用交叉熵损失以衡量预测概率 $\hat{y}$ 与真实标签 y 的差异。这个衡量的函数被称为损失函数, 具体公式如下:

$$J(\mathbf{w}, b) = -\frac{1}{N} \sum_{i=1}^N \left[y^{(i)} \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right] \quad (2.4)$$

其中:

N 为样本数量;

$y^{(i)}$ 为第 i 个样本的真实标签;

$\hat{y}^{(i)}$ 为第 i 个样本的预测概率。

通过各种方式使损失函数最小化, 便能得到一个对应需求的拟合模型, 进而预测未来客户的风控标签, 其简单易懂的原理在贷前评分卡中深受欢迎。然而随着数据科学的深入发展, 近几年来在非线性关系捕捉以及预测性能上涌现了众多更具备优秀性能的模型方法 (如树模型、深度学习网络等), 目前在消费金融机构中已被 LightGBM 等树结构替代。下面本文将介绍树结构模型在风控领域上的一点技术原理。

2.2.3 树模型架构

树模型是一种基于特征空间划分的具有树形分支结构的模型, 具有无量纲要求、多规则组成、能够处理数值型和类别型数据、有较高应用解释性的特点。决策树便是其中一种常见的树模型, 主要可用于分类与回归, 对输入变量、输出变量没有连续性要求, 其核心思想是通过一系列规则 (if-then 结构) 对数据进行递归划分, 最终形成一棵树来预测目标变量。由于决策树分枝直观性较强, 该特点使其成为数据探索和解释性建模的常用工具, 在风控领域搭建规则引擎以及查看特征重要性时得到广泛使用。

2.2.4 XGBoost 模型原理

XGBoost 是一种基于决策树的集成算法, 主要采用了 Boosting 的思想并使用梯度提升技术来提高模型的准确性和泛化能力。因其较好的预测效果被广泛应用于机器学习竞赛和工业界。

XGBoost 属于加法模型, 通过迭代地训练多个弱学习器 (通常是决策树), 并将它们的预测结果加权求和, 逐步优化模型。每一轮迭代会新增一棵树, 拟合当前模型的残差 (即前一轮模型的预测误差)。

总体目标函数具体如下:

$$Obj^{(t)} = \sum_{i=1}^n L(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \sum_{k=1}^t \Omega(f_k) \quad (2.5)$$

其中:

$y_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$ 是第 t 轮迭代的预测值;

$\Omega(f_k)$ 是第 k 棵树的正则化项。

对单棵树的正则化项为（控制叶子节点权重和数量）：

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.6)$$

其中：

T 是叶子节点数量；

w_j 为第 j 个叶子节点的权重；

γ, λ 为超参数。

相较于传统 GBDT 算法而言，XGBoost 最为着重不同的是其损失函数。传统 GBDT 算法主要以一阶梯度作为损失函数，而 XGBoost 使用二阶泰勒展开作为损失函数，具体损失函数如下：

$$Obj^{(t)} \approx \sum_{i=1}^n \left[L(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (2.7)$$

其中：

$$g_i = \frac{\partial l(y_i, \hat{y}_i)}{\partial \hat{y}_i} \quad (2.8)$$

$$h_i = \frac{\partial^2 l(y_i, \hat{y}_i)}{\partial \hat{y}_i^2} \quad (2.9)$$

经移除常数项后带入正则化项，进一步按叶子节点分组，目标函数化简为：

$$Obj^{(t)} = \sum_{j=1}^T \left[\left(\sum_{i \in I_j} g_i \right) w_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) w_j^2 \right] + \gamma T \quad (2.10)$$

2.2.5 LightGBM 核心原理

LightGBM 是微软开发的一种基于决策树算法的梯度提升框架，具有高效、快速的特点。其核心原理基于梯度提升迭代训练多棵决策树，每棵树学习前一阶段的残差。LightGBM 目标函数：

$$Obj = \sum_{i=1}^n L(y_i, \hat{y}_i) + \sum_{k=1}^K \left(\gamma T + \frac{1}{2} \lambda \|w\|^2 \right) \quad (2.11)$$

其中梯度 g_i 和二阶梯度 h_i 通过直方图分桶统计。

它通过三大创新优化效率：1) 基于直方图的算法将连续特征分桶加速计算；2) 单边梯度采样 (GOSS)：保留大梯度样本并随机采样小梯度样本；3) 同时采用 Leaf-wise 生长策略直接分裂增益最大的叶子节点。受上述三大创新技术调整影响，LightGBM 模型相对基础的决策树框架有着更快的大规模数据处理速度以及对

类别型特征的更强适应性。

2.2.6 Catboost 核心原理

这里将开始讲述另外一种同样基于梯度提升框架下的决策树模型——Catboost。该模型核心创新在于利用有序提升机制通过排列组合方式防止梯度偏差,采用有序目标编码自动高效处理类别特征避免数据泄露,并构建对称树结构提升预测速度和稳定性。

相比传统 GBDT, Catboost 在减少过拟合、自动处理类别变量、降低超参数敏感性具备一定优势,特别适合包含大量类别特征的应用场景。

在金融风控策略构建过程中,大数据集一般格式混杂,因此在工业处理上为增强解释性类别型数据经常需要额外的业务特殊编码及分箱。为提高工作效率,具备对类别变量有更强应用性以及高效能该两大优点的模型将得到风控策略分析师的青睐。

2.2.7 算法对比

阅读下表 2.2,从核心原理以及性能两方面分别对比 XGBoost、LightGBM 以及 Catboost 三个模型,可以了解: XGBoost 在预测精度以及防过拟合上有着较好的优势,但训练较慢,适用于中小型数据集;而 LightGBM 基于直方图的算法原理为处理高维特征带来了较好的优势同时在三类模型中具备最快的训练速度,适用于大规模数据的工业场景; Catboost 同样作为 GBDT 算法在类别型特征处理上有着较强的自主适应性与处理优势。

识别风控场景需求,工业处理通用性、类别特征处理以及大规模数据的处理速度该三点要求使得本次建模过程中着重选择了 LightGBM 与 Catboost 两个模型的相结合。

另外值得一提的是,树模型尤其是 LightGBM 在风控行业内近年来尤其是注重区分度的消费金融公司而言得到广泛使用。然而由于银行、证券业等出于法律合规性的思考,对特征的解释性要求较高,还在 Logistics Regression 使用阶段。

表 2.2 机器学习算法性能对比

维度	XGBoost	LightGBM	Catboost
训练速度	慢（适合精确需求）	极快（大规模数据）	中等（类别特征多时优势明显）
内存占用	高	低	中等
精度	高（预排序算法）	中等（直方图近似）	高（尤其类别特征）
类别特征	需手动编码	需手动编码	原生支持
过拟合风险	低（正则化强）	中（Leaf-wise 生长）	低（对称树结构）
最佳场景	中小数据、精确模型	大规模数据、高维特征	类别特征多、需鲁棒性
基础算法	梯度提升决策树（GBDT）	基于直方图的 GBDT	对称 GBDT
树生长策略	按层分裂	按增益最大分裂	平衡二叉树
特征处理	预排序算法（精确分裂）	直方图分桶（近似分裂）	类别特征自动处理 + 特征组合
缺失值处理	自动学习缺失值方向	自动处理	自动处理
正则化	L1/L2 正则化+复杂度控制	类似 XGBoost	L2 正则化+梯度噪声注入

第三章 需求分析与架构设计

3.1 论文核心问题阐述

本论文中心问题：如何通过创新数据手段从而提高风控响应效率？

在传统信贷风控模式中，会计资产审查、人工审核以及专家规则调研是主流的控制手段。然而随着时间发展，上述三种主流手段虽然可以在一定程度上拦截部分高风险借贷需求，但人工精力消耗高，个别情况下难以辨认出欺诈信息等缺点随时间开始显现，而机器学习的发展为贷前预测违约、评分在海量的用户申请信息中找到了一定的新发展立足点。本文主要关注贷前违约预测，通过贷前拦截部分高风险客户的放贷申请从而达到减少坏账的情况。

参考上述思路，本研究将采用大数据建模的方式搭建违约预测模型，并从模型中捕捉一定的关系因子对未来风控模型策略创新进行解读。对此，本文核心问题同时等价于如何利用大数据建模搭建贷款违约风险预测模型。由此拆解可知为实现模型，需要解决的问题具体如下：

数据源来自哪里？是否具备可靠性？

数据该如何进行处理才可以进行建模使用？

该如何进行建模？

- 采用什么方法进行建模？
- 输入变量是什么？输出变量是什么？

如何评估模型效果？

如何优化模型预测能力？

从预测模型中有什么值得关注的点值得风控领域借鉴学习？

3.2 模型需求分析

根据研究背景与实际应用需要，将模型的需求分为功能需求与非功能需求。

功能需求是模型应实现的目标，即通过数据预测申请用户的违约概率情况，其中准确性与泛化性将成为模型重点关注问题。

模型在实现预测功能的同时，还需要保证模型本身运行的可移植性和运行效

率，故非功能需求如下：

- （1）模型运行流畅度：海量的申请用户信息以及第三方接口数据为模型的运行消耗带来了一定挑战，在代码中如何有效运用内存机制进行模型训练需得到关注。
- （2）模型工业使用需求合规性：在竞赛与科研里，采用最高精度的模型抛弃运行速率是可取的，然而风控模型有着其独特的应用场景需求，受制于海量的大数据信息若一味采用高精度模型训练而放弃了速率，会导致企业失去灵活应对借贷评测的优势，因此在建立模型时也应着重思考模型对应工业需求灵活性的体现。
- （3）模型可扩展性：能够在对现有模型影响最小的情况下，同时能保持可持续扩展和稳定提升的能力。

3.3 模型总体架构

根据需求分析，模型架构主要分多层设计，其中数据类层是整个模型的信息基础，模型层通过调用两类模型来优化建模。交互层则负责将模型结果链接公式进行评分调准，以此输出给用户申请。



图 3.1 论文模型架构层次图

第四章 基于数据集的违约预测模型构建

4.1 违约预测对象介绍

本节将介绍本论文选取的研究对象。本文主要采取 Kaggle HomeCredit Risk Default Analysis 比赛由 Homecredit 机构公开发布的数据集作为基础数据源进行分析与建模。

HomeCredit（中文名：捷信）是一家国际领先的消费金融服务提供商，核心业务涵盖消费分期贷款、现金贷、信用卡服务等，通过与零售商、线上平台合作，为消费者提供“先买后付”（Buy Now, Pay Later）的普惠金融服务。公司成立于 1997 年，总部位于荷兰，业务遍布欧亚多个市场，包括中国、印度、俄罗斯、印尼、越南等国家。目前在东南亚、拉美国家中目前已占据头部消费金融地位。

因此本文通过对 HomeCredit 自主披露的信息进行建模分析，在消费金融风控策略上具备一定代表性，能够对消费金融风控策略的发展提供一定实践意义。



图 4.1 HomeCredit 公司 LOGO

4.2 建模环境介绍

本次实验研究基于大规模数据集建模，所有计算任务均通过云端接入 Kaggle 竞赛平台服务器完成。硬件配置采用英特尔至强处理器 Intel(R) Xeon(R) Platinum 8275CL (32 线程) 与 NVIDIA Tesla T4 双卡并联方案 (单卡显存 16GB)。通过 CUDA 11.7 与对应版本的 CUDNN 加速库实现 GPU 并行计算加速，同时借助 Sklearn、Pandas、Numpy 等科学计算工具库进行数据预处理与结果验证，开发环境使用 Anaconda Python3 Notebook 远程连接云端服务器进行代码编写与调试。实验全程依托 Kaggle 平台提供的 T4×2 GPU 集群与高性能 CPU 计算资源完成模型训练与推理任务。

4.3 数据集解读与数据预处理

本文解析数据集共计 1526659 条，比赛方从个人基本资料 (性别、年龄、学历等)，财务情况，消费与交易记录 (每月消费金额、限制消费原因等)，第三方征信 (用户名下所有开户行、级别等) 等多角度共计提供了 465 个原生的特征。基于以上数据与特征，本文做出了以下处理：

4.3.1 数据格式处理

```
class Utility:
    @staticmethod
    def get_feat_defs(ending_with: str) -> None:

        feat_defs: pl.DataFrame = pl.read_csv(ROOT / "feature_definitions.csv")

        filtered_feats: pl.DataFrame = feat_defs.filter(
            pl.col("Variable").apply(lambda var: var.endswith(ending_with))
        )

        with pl.Config(fmt_str_lengths=200, tbl_rows=-1):
            print(filtered_feats)

        filtered_feats = None
        feat_defs = None

    @staticmethod
    def find_index(lst: list[Any], item: Any) -> int | None:
        try:
            return lst.index(item)
        except ValueError:
            return None

    @staticmethod
    def dtype_to_str(dtype: pl.DataType) -> str:
        dtype_map = {
            pl.Decimal: "Decimal",
```

图 4.2 Utility 类示意图

鉴于个人数据繁多，特征类别众多，为方便理解与后续训练处理，主要通过定义类编写函数的调用处理方式进行了以下整理：

首先，定义 Utility 类并编写预处理工具函数，方便调用，主要代码以及各函数功能具体可阅读表 4.1：

表 4.1 预处理函数整理

函数名	作用
find_index()	在列表中查找元素的索引
dtype_to_str()	将 polars 数据类型转换为字符串表示
find_feat_occur()	查找特征在 Parquet 文件中的出现情况
reduce_memory_usage()	通过优化数据类型减少内存使用
to_pandas()	将 polars DataFrame 转换为 pandas DataFrame
change_dtypes()	转换列的数据类型
scan_files()	扫描并加载 Parquet 文件
join_dataframes()	合并不同深度的数据框

4.3.2 缺失值与异常值处理

因赛方备注，本次数据集处理上无异常值待处理。

缺失值上，主要对数据缺失超 200 条的以及个别特征列仅有一个数值的数据进行了清除处理。

- 缺失超 200 条的处理逻辑如下：
- (1) 使用 isna.sum()查找整理好的数据框的每列空缺值；
 - (2) 数据框筛选空缺值大于 200 的列，将列名输出为一个列表；
 - (3) 指定列名列表为丢弃对象，使用 drop()函数丢弃。
- 仅有一个数值的数据框处理逻辑如下：
- (1) unique 函数嵌套 len，循环查找每一列具备的数值数量情况；
 - (2) 数值数量为 1 的列的列名输出为一个列表；
 - (3) 指定列名列表为丢弃对象，使用 drop()函数丢弃。
- 经处理，数据集余下 352 个原生特征。

4.4 特征工程——特征衍生与数据聚合

4.4.1 消费水平

阅读特征定义表后，共计选出 15 个有关于用户个人消费水平的特征变量，并分别按数值类型分为连续型变量与离散型变量。

以下为具体的消费相关变量：

表 4.2 消费变量整理

变量名称	描述	类型
amtdebitincoming_4809443A	入账的借记卡交易金额	连续型
amtdebitoutgoing_4809440A	出账的借记卡交易金额	连续型
amtdepositbalance_4809441A	客户的存款余额	连续型
amtdepositincoming_480944A	客户账户的入账存款金额	连续型
amtdepositoutgoing_480944A	客户账户的出账存款金额	连续型
last180dayaveragebalance_704A	过去 180 天的平均借记卡 余额	连续型
last180dayturnover_1134A	过去 180 天的借记卡交易 额	连续型
last30dayturnover_651A	过去 30 天的借记卡交易额	连续型
pmtaverage_3A	税收扣除的平均值	连续型
pmtaverage_4527227A	税收扣除的平均值	连续型
pmtaverage_4955615A	税收扣除的平均值	连续型
pmtcount_4527229L	税收扣除的次数	离散型
pmtcount_4955617L	税收扣除的次数	离散型
pmtcount_693L	税收扣除的次数	离散型
pmtssum_45A	客户的税收扣除总额	连续型

对于连续型特征，主要通过按 group 求各特征的平均值、标准差、中位数、最小值、最大值。

对于离散型特征，主要通过按 group 求各特征下的类别计数以及每列不同值的个数。

```
class Aggregator:
    @staticmethod
    def max_expr(df: pl.LazyFrame) -> list[pl.Series]:

        cols: list[str] = [
            col
            for col in df.columns
            if (col[-1] in ("P", "M", "A", "D", "T", "L")) or ("num_group" in col)
        ]

        expr_max: list[pl.Series] = [
            pl.col(col).max().alias(f"max_{col}") for col in cols
        ]

        return expr_max

    @staticmethod
    def min_expr(df: pl.LazyFrame) -> list[pl.Series]:

        cols: list[str] = [
            col
            for col in df.columns
            if (col[-1] in ("P", "M", "A", "D", "T", "L")) or ("num_group" in col)
        ]

        expr_min: list[pl.Series] = [
```

图 4.3 Aggregator 类定义示意图

以上衍生操作主要通过定义聚合类编写函数进行衍生，详细函数如表 4.3:

表 4.3 聚合类函数整理

函数名	作用
max_expr	提取特征列最大值
Min_expr	提取特征列最小值
Var_expr	提取特征列方差
Mode_expr	提取特征列众数
Get_expr	将衍生统计量与特征链接

4.4.2 消费行为变化

行为变化上，主要通过处理日期相关特征，计算该特征在数据集给予的当前日期与决策日期二者之间以天数为单位的差值记录。

```
def handle_dates(df: pl.DataFrame) -> pl.DataFrame:

    for col in df.columns:
        if col.endswith("D"):
            df = df.with_columns(pl.col(col) - pl.col("date_decision"))
            df = df.with_columns(pl.col(col).dt.total_days().cast(pl.Int32))

    df = df.rename(
        {
            "MONTH": "month",
            "WEEK_NUM": "week_num"
        }
    )

    df = df.with_columns(
        [
            pl.col("date_decision").dt.year().alias("year").cast(pl.Int16),
            pl.col("date_decision").dt.day().alias("day").cast(pl.UInt8),
        ]
    )

    return df.drop("date_decision")
```

图 4.4 日期特征处理示意图

综上，在经过特征衍生后共计存在 472 条特征，对应连接 case_id 与日期进行数据聚合，形成了本次建模的最终训练集与测试集数据(如图 4.5)。

Train data shape: (1526659, 472)
shape: (10, 472)

case_id	month	week_num	target	assignmentdate_238D	assignmentdate_4527235D	birthdate_574D	contractssum_5085716L	dateofbirth_337D	days120_
u32	u32	u8	u8	i16	u8	i16	f32	i32	
1398131	201906	23	0	null	null	-15411	null	-15411	
2637394	201911	43	0	null	null	null	null	-17624	
731695	201907	26	0	null	null	-15858	null	-15858	
1506909	201908	34	0	null	null	null	null	-13356	
839592	201910	42	1	null	null	null	null	-15332	
1453863	201907	28	0	null	null	-14506	null	-14506	
1650123	201911	47	0	null	null	null	null	-10770	
1273502	201902	5	0	null	null	-11358	null	null	
1388830	201906	22	0	null	null	-8953	null	-8953	
1623098	201911	44	0	null	null	null	null	-13707	

图 4.5 处理好的数据集

4.5 模型训练与评估

经过上述预处理以及特征工程后，结合风控具体业务需求进行数据集探索，本文发现在预测违约样本类别时存在好坏类别不平衡的情况。

为解决本文数据集中优秀样本（标记为 1）数量较少的问题，随机划分可能导致某些 fold 的类别比例与整体数据不一致，影响模型评估的准确性，因而相比通用的随机五折交叉法，本文在随机划分五折前对类别进行统计，以保证划分抽取时每一份的类别比例与原始数据大致一致，也就是所谓的 Stratified 五折交叉训练。

而在模型选取训练中，考虑到上文的理论基础对比、需求分析以及工业应用便携性，通过对比贷前常用的三类模型：XGBoost\LightGBM\Catboost。处于对类

别型变量的适应性要求与训练效率的考虑，最终选择了 LightGBM 与 Catboost 二者。

综上本文采用 Stratified 五折交叉法按周数对数据进行分层随机分组，并以此采用双模型策略分别训练 LightGBM 与 Catboost。

以下为本文训练 LightGBM 以及 Catboost 的 AUC Score 表现对比如图 4.6:



图 4.6 AUC 分数对比

4.6 特征重要性分析

在 LightGBM 训练中，模型对输入特征的重要性进行了一定输出。




图 4.7 Top20 特征重要性 (LightGBM)

根据图 4.7 结合业务解释，本文归纳出三个角度，帮助业务识别出可以较好区分好坏用户的潜在风控规则策略。具体如下：

表 4.4 特征分类解释

客户还款能力	支付历史行为	逾期历史记录
利率	客户已进行的贷款支付总数	活跃合同的最大逾期金额日期
信贷价格	已关闭信贷合同的开始日期	活跃合同的最大逾期金额
活跃合同的剩余金额	上一次申请的就业开始日期	
信贷局的活跃合同分期付款金额		

从信息增益角度看，客户还款能力、支付历史行为、逾期历史记录以及各特征结合时间动态记录的个体状态变化在违约预测中有着较强的区分度。结合业务逻辑而言，逾期历史记录如最大逾期金额及逾期天数在风险预测中高度相关，由此可以在贷前检测应用中将历史逾期金额结合其他显著性特征设定阈值一起作为风控策略规则，进而控制通过率、坏账率。此外诸如客户个人还款行为记录等特征结合时间观测到的状态变化在预测中也有着较大的助力作用。

4.7 模型优化

4.7.1 投票机制与线性融合

为提高预测性能并降低单一模型的过拟合风险，本研究采用基于 Stacking 集成结合 LightGBM 与 Catboost 的差异化优势，并引入投票机制与简单平均概率以优化最终输出。

本文训练的模型结果为概率，因此本文优化机制中的投票以等权重的软投票为主。概率加权平均函数为：

$$\bar{p}_j = \frac{1}{n} \sum_{i=1}^n p_{ij} \quad (4.1)$$

其中：

n 为模型个数，本文显示指定为 2；

p_{ij} 表示第 i 个模型对类别 j 的预测概率，本文中 $j = 1, 2$ ；

$\bar{p}_j$ 表示类别 j 的平均预测概率。

最终预测类别：

$$\hat{y} = \arg \max_j \bar{p}_j \quad (4.2)$$

其中， $\hat{y}$ 表示最终预测的类别。

结果输出如图 4.8：

case_id	score
57543	0.010445
57549	0.043476
57551	0.002551
57552	0.015798
57569	0.123437
57630	0.008071
57631	0.032156
57632	0.008813
57633	0.037925

图 4.8 模型预测结果文件读取

经 AUC 的结果对比（如图 4.9），集成后的模型 AUC 分数有一定程度提升。因而认为集成有效。




图 4.9 模型性能对比（集成前后）

4.7.2 基于时间信息的预测结果微调

由于数据集中部分用户信息更新时间不一，用户信息距离上一次更新时间越久，模型预测失效的风险越高，违约概率也更易偏高。因此在集成训练后将预测概率结果对应上一次更新时间进行微调。从业务逻辑思考，同样的特征输入，距离上一次更新时间越短的用户在原有预测的违约概率基础上加权重对应降低。

主要调整逻辑如下：

- (1) 取 Week_num 的中位数作为衡量更新时间新旧程度的基线；
- (2) 离现在越近且高于基线的用户对应预测概率手动降低 1%，最低值为 0。

经 t 检验，调整前后差异显著。因而认为调整在稳定性上有一定效果。

```
from scipy import stats

def perform_t_test(original_scores, adjusted_scores):
    t_stat, p_value = stats.ttest_rel(original_scores, adjusted_scores)
    print(f"\n配对t检验结果:")
    print(f"t统计量: {t_stat:.4f}")
    print(f"p值: {p_value:.4f}")
    if p_value < 0.05:
        print("结论: 调整前后差异显著 (p < 0.05)")
    else:
        print("结论: 调整前后差异不显著 (p ≥ 0.05)")

# 对集成模型进行检验
perform_t_test(results['ensemble_original'], results['ensemble_adjusted'])
```

配对t检验结果:
t统计量: 11.1475
p值: 0.0004
结论: 调整前后差异显著 (p < 0.05)

图 4.10 实验代码及结果显著

第五章 可视化应用与用户管理

5.1 分数校准

通常而言，业务会将模型输出的概率通过分数校准转换为整数分数。本文将效仿芝麻信用，遵循用户模型分越高，信用风险越小的原则。该分数校准行为适用于用户管理层面，有助于业务层激励用户积极还贷的情况。

5.1.1 评分公式原理

$$Score = A - B \ln(Odds) \quad (5.1)$$

其中：

Score 是最终的信用评分；

A 和 B 是用于调整信用尺度的常数。

Odds 是违约概率的比值，计算公式为：

$$Odds = \frac{p}{1-p} \quad (5.2)$$

其中：

p 为违约概率，即本文模型输出的最终概率。

计算常数 A 与 B 的公式如下：

$$B = \frac{PDO}{\ln(2)} \quad (5.3)$$

$$A = p_0 + B * \ln(\theta_0) \quad (5.4)$$

其中：

p_0 为基准分数，本文指定为 $p_0 = 600$ ；

θ_0 为基准 Odds， $\theta_0 = \frac{1}{15}$ ；

PDO 是当 Odds 翻倍时，信用评分的变化值，本文指定为 50。

5.1.2 评分链接实例

为方便后续用户交互自主管理信用，模型最终的输出结果链接上述，对应用户id生成信用评分。具体代码如图 5.1:

```
def calculate_constants(P0 = 600, theta0 = 1/15 , PDO = 50):
    B = PDO / np.log(2)
    A = P0 + B * np.log(theta0)
    return A, B

def calculate_score(p, A, B):
    odds = p / (1 - p)
    score = A - B * np.log(odds)
    return score

A, B = calculate_constants()
A, B
(404.65547021957406, 72.13475204444818)
```

图 5.1 概率与评分链接的代码示图

通过函数 calculate_score 对应 id 及输出概率的循环获取，最终信用评分如图 5.2 所示。

case_id	score	score_credit
57543	0.010445	732.953735
57549	0.043476	627.630626
57551	0.002551	835.210124
57552	0.015798	702.712501
57569	0.123437	546.059814
57630	0.008071	751.724553
57631	0.032156	650.235972
57632	0.008813	745.326960
57633	0.037925	637.901687

图 5.2 评分输出（部分）

现实场景中，获取评分后，根据运营设置的任务体系（如蚂蚁森林种树等）在该原有评分基础上增减变动，最终输出至用户端交互界面，以此形成透明的信用评分量化体系。

第六章 总结与展望

6.1 总结

6.1.1 工作总结

本文通过设计基于现有数据集的违约预测模型，从个人基本信息、消费行为以及个人状态变化解读用户个人，并相应进行违约概率预测。在建模过程中，本文进行了理论探讨、数据清洗、特征工程、模型训练与优化以及最后的评分可视化。通过训练，本论文从特征重要性角度挖掘了与违约样本高度相关的特征，从业务解释与阈值层面对风控策略的未来制定做出一定指引。

在理论探讨方面，本论文首先通过介绍信用评分卡的具体内容与应用示例，展现了目前信贷风控策略领域的一些简单工具，并由此从评分卡建模领域引出了本文的重点在于机器学习手段在现代评分卡建设的具体应用。随后详细讲解了目前市面上较为流行使用的机器学习算法，并对本次数据建模的具体应用场景进行了阐述说明。

在数据清洗方面，本论文通过定义 `Utility` 类编写多个预处理函数，主要涉及类别转换、数据框转换等。关于异常值与空缺值处理上，主要关注空缺值在缺少较多维度以及特征值单一的情况进行去除处理。

在模型训练与优化中，本论文通过理论探讨以及数据探索发现数据集样本存在类别不平衡以及类别特征较为繁多的情况，因而采用 `Stratified` 五折交叉训练法加以 `LightGBM` 与 `Catboost` 双模型训练。为较好融合双模型，采用等权重软投票机制对结果进行了融合。同时考虑到用户样本在时间动态变化上的鲁棒性，对数据更新时间较新的用户降低违约概率，进而作为最终结果。

通过可视化交互，本论文实现的模型通过信用评分公式表现出良好的性能与效果，具备工业应用性。

6.1.2 局限性

(1) 由于数据集需要进行大量的物理计算，对计算资源要求较高，基于现实本论文的代码实现过程会出现较为缓慢甚至多次崩溃重做现象。

(2) 特征重要性分析中提取出的相关特征，后续可通过因果推断的科学检验，验证与违规概率的具体关系。

(3) 本文对于时间新旧程度进行概率调整的逻辑较为简单，有可能导致脱离现实动态变化。所以如何进一步引入对用户信息更新调整评分敏感度的实验也是未来研究的一个重要方向。

6.1.3 展望

在基于 HomeCredit 数据的模型设计中，本节将探讨针对模型方法与结果对现实生活做出一定指引。

(1) 风控策略规则以及规制阈值方面，除却市面上流行的决策树，还可以从其他树模型的训练中获取特征重要度并排序，进而捕捉人为经验难以捕捉到的非线性关系。

(2) 在用户交互方面，信用分不仅仅靠简单的信用卡评分公式生成。在用户管理以及 APP 运营方面，引用用户活跃任务机制辅以评分加减，有助于评分机制动态化，同时帮助用户促活。

致谢

在这篇论文完成之际，我的本科生生活也将接近尾声。本科生活转瞬即逝，在这里我收获了知识，收获了成长，回首往昔，我的内心充满感激。

首先，要感谢本论文的指导老师杨海霞老师，正是她在我论文写作过程中的悉心指导，才能让我能顺利完成毕业论文的撰写。

同时感谢我的家人，尤其是我的母亲。家人的支持，是我完成学业的必要保障。走在当下，很感谢家人们支持我的每一次选择，在每一个分叉口给予我信心去思考与选择。

大四这一年体验了不同的实习与不同环境下的职场社会化。越来越发现人生很多分叉口上，是一次次勇敢者的长跑游戏。足够勇敢，才有机会去得到想要的选择，去面对所有的结果。选择可能不是时时到来，但做好长跑的准备，只要一直跑，选择便随时有可能掉在路边迎接着你。

感谢一路上陪伴我的同学好友，在困苦之际给予我肯定与支持。

风物长宜放眼量，人生之路走走停停，一路皆是风景。不管是成功，亦或是失败，一切都值得纪念和回味。感谢恩师、感恩生命、感受青春，我将“艰苦朴素，求真务实”的校训铭记在心，伴我扬帆远行。

参考文献

- [1] 艾瑞咨询. 2023 年中国消费金融行业研究报告[R]. 上海: 艾瑞研究院, 2023.
- [2] 曹伟萍, 张劲松. 基于不平衡数据处理与加权软投票异质集成的农户贷款违约风险预测[J/OL]. 计算机应用与软件, 2025: 1-10.
- [3] 陈玉沂, 刘高勇, 蔡焕仪. 个人信贷违约预测机器学习模型的解释性方法研究[J]. 现代计算机, 2024, 30(13): 68-72.
- [4] 迟国泰, 杨佳琦, 周颖. 基于最优临界点的债券违约动态预警研究[J]. 管理科学学报, 2024, 27(11): 136-158.
- [5] 胡俊, 李强, 曾勇, 等. 数字足迹与违约预测: 基于消费信贷的证据[J]. 管理科学学报, 2025, 28(02): 115-139.
- [6] 黄雅静. 基于随机森林模型融合的贷款违约预测[D]. 天津: 南开大学, 2021.
- [7] 赖维彬. 基于CatBoost堆叠法的P2P信贷违约预测研究[D]. 南昌: 江西财经大学, 2023.
- [8] 李思晗. 基于改进的Stacking集成算法的信贷风控研究[D]. 成都: 西南财经大学, 2024.
- [9] 刘华玲, 张国祥, 王柳月. 基于异构信息网络的信贷反欺诈研究[J]. 计算机科学, 2023, 50(S2): 684-692.
- [10] 刘满虎. 基于LightGBM的某商业银行信贷违约风险预测研究[D]. 重庆: 重庆大学, 2023.
- [11] 王龙超, 柴朝华, 时昊怡. 大数据智能风控平台的架构、设计与实现[J]. 大众标准化, 2021(22): 67-70.
- [12] 王梦雪. 基于机器学习技术的P2P风控模型研究[D]. 哈尔滨: 哈尔滨工业大学, 2017.
- [13] 王柠, 马鸣娇, 王从飞. 消费金融公司 2024 年发展回顾及 2025 年展望[R]. 北京: 联合资信评估股份有限公司, 2024.
- [14] 王星, 王静. 大数据风控: 数据、模型与算法[M]. 北京: 电子工业出版社, 2021.
- [15] 中诚信国际. 中国消费金融公司展望(2025 年 1 月)[R]. 北京: 中诚信国际信用评级有限责任公司, 2025.

- [16]Anderson, R. (2007). The credit scoring toolkit: Theory and practice for retail credit risk management and decision automation. Oxford: Oxford University Press.
- [17]Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- [18]Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.
- [19]Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232.
- [20]Hand, D. J., & Henley, W. E. (1997). Statistical classification methods in consumer credit scoring: A review. *Journal of the Royal Statistical Society: Series A*, 160(3), 523-541.
- [21]Hosmer, D. W., Jr., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3rd ed.). Hoboken: Wiley.
- [22]Ke, G., Meng, Q., Finley, T., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146-3154.
- [23]Kim, H., Cho, H., & Ryu, D. (2020). Forecasting consumer credit recovery failure: Classification approaches. *Journal of Credit Risk*, 17(3), 45-60.
- [24]Liu, Z., Chen, C., Yang, X., Zhou, J., Li, X., & Song, L. (2022). Heterogeneous graph neural networks for malicious account detection. *Proceedings of the 28th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2077-2085.
- [25]McMahan, H. B., Moore, E., Ramage, D., et al. (2017). Communication-efficient learning of deep networks from decentralized data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, 1273-1282.
- [26]Prokhorenkova, L., Gusev, G., Vorobev, A., et al. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638-6648.
- [27]Siddiqi, N. (2006). *Credit risk scorecards: Developing and implementing intelligent credit scoring*. Hoboken: Wiley.
- [28]Thomas, L. C., Edelman, D. B., & Crook, J. N. (2002). *Credit scoring and i*

ts applications. Philadelphia: SIAM.

- [29] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998-6008.
- [30] Yang, Q., Liu, Y., Chen, T., & Tong, Y. (2019). Federated machine learning: Concept and applications. *ACM Transactions on Intelligent Systems and Technology*, 10(2), 1-19.

附录

(一) 特征衍生代码 (操作: 最大值、最小值、均值、众数及聚合)

```
class Aggregator:
    @staticmethod
    def max_expr(df: pl.LazyFrame) -> list[pl.Series]:
        cols: list[str] = [
            col
            for col in df.columns
            if (col[-1] in ("P", "M", "A", "D", "T", "L")) or ("num_group" in col)
        ]

        expr_max: list[pl.Series] = [
            pl.col(col).max().alias(f'max_{col}') for col in cols
        ]

        return expr_max

    @staticmethod
    def min_expr(df: pl.LazyFrame) -> list[pl.Series]:
        cols: list[str] = [
            col
            for col in df.columns
            if (col[-1] in ("P", "M", "A", "D", "T", "L")) or ("num_group" in col)
        ]

        expr_min: list[pl.Series] = [
            pl.col(col).min().alias(f'min_{col}') for col in cols
        ]
```

```
return expr_min
```

```
@staticmethod
```

```
def mean_expr(df: pl.LazyFrame) -> list[pl.Series]:
```

```
    cols: list[str] = [col for col in df.columns if col.endswith(("P", "A", "D"))]
```

```
    expr_mean: list[pl.Series] = [
```

```
        pl.col(col).mean().alias(f"mean_{col}") for col in cols
```

```
    ]
```

```
    return expr_mean
```

```
@staticmethod
```

```
def var_expr(df: pl.LazyFrame) -> list[pl.Series]:
```

```
    cols: list[str] = [col for col in df.columns if col.endswith(("P", "A", "D"))]
```

```
    expr_mean: list[pl.Series] = [
```

```
        pl.col(col).var().alias(f"var_{col}") for col in cols
```

```
    ]
```

```
    return expr_mean
```

```
@staticmethod
```

```
def mode_expr(df: pl.LazyFrame) -> list[pl.Series]:
```

```
    cols: list[str] = [col for col in df.columns if col.endswith("M")]
```

```
    expr_mode: list[pl.Series] = [
```

```
        pl.col(col).drop_nulls().mode().first().alias(f"mode_{col}") for col in
```

```
cols
```

```
    ]
```

```
    return expr_mode
```

```
@staticmethod
def get_exprs(df: pl.LazyFrame) -> list[pl.Series]:
    exprs = (
        Aggregator.max_expr(df)      +      Aggregator.mean_expr(df)      +
        Aggregator.var_expr(df)
    )

    return exprs
```

(二)时间调准

```
condition = X_test[col] < (X_test[col].max() - X_test[col].min())/2 + X_test[col].min()
df_subm.loc[condition, 'score'] = (df_subm.loc[condition, 'score'] - 0.01).clip(0)

df_subm.to_csv("submission.csv")
```